Szekvenciális fájlok kezelése

Gregorics Tibor

gt@inf.elte.hu

http://people.inf.elte.hu/gt/oep

Szekvenciális inputfájl

- □ A szekvenciális inputfájl (infile(E)) elnevezést olyan gyűjteményre használjuk, amelynek elemeit (amelyek mind egy adott E halmazhoz tartoznak) sorban egymás után szeretnénk kinyerni.
- □ Egy ilyen gyűjteményre olyan sorozatként tekintünk (a reprezentációja többnyire tényleg egy sorozat), amelyre egyetlen műveletet engedünk csak meg: a sorozat első elemének "kiolvasását" (leszakítását).
- □ Az olvasást az st, e, x : read szimbólummal jelöljük (ami egy értékadásra utal: st, e, x:=read(x)), ahol x:infile(E), e:E, st:Status = {abnorm, norm}, és amely az alábbi tevékenységet fedi:

```
if x = <> then st := abnorm

else st, e, x := norm, x_1, <x_2, ..., x_{|x|}>
```

Szekvenciális outputfájl

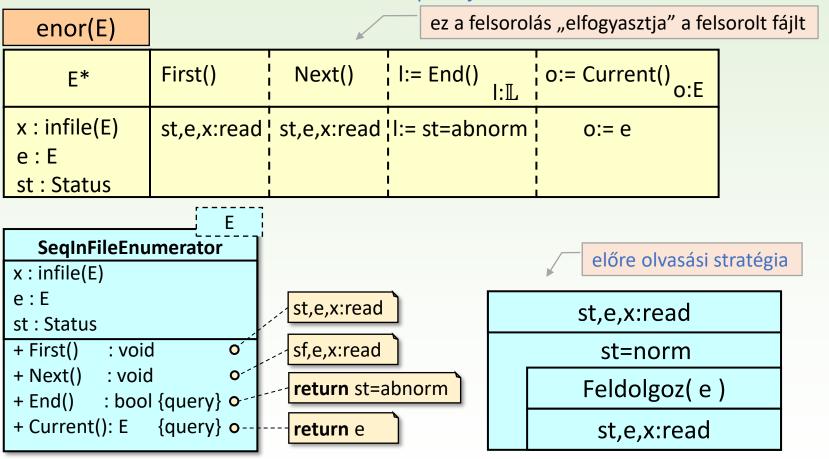
- □ A szekvenciális outputfájl (outfile(E)) elnevezést olyan gyűjteményre használjuk, amelybe sorban egymás után helyezhetünk el egy adott E halmazhoz tartozó elemeket.
- □ Egy ilyen gyűjteményre olyan sorozatként tekintünk (a reprezentációja többnyire tényleg egy sorozat), amelyre két műveletet vezetünk be:
 - 1. kezdetben az üres sorozat létrehozását
 - 2. a sorozat végéhez történő hozzáírást (hozzáfűzést)
- □ Az inicializálást az x := <> értékadás végzi, ahol x:outfile(E), és <> az üres sorozat.
- Az írást az x : write(e) szimbólummal jelöljük (ami az x := write(x, e) értékadásra utal), ahol x:outfile(E), e:E, és amely az alábbi tevékenységet fedi: x := x ⊕ <e>

Fájlkezeléses feladatok

- □ A gyakorlatban sokszor találkozhatunk olyan feladatokkal, amelyekben szekvenciális inputfájl (esetleg több fájl) alapján kell elállítani szekvenciális outputfájlt (esetleg fájlokat):
 - másolás
 - kiválogatás
 - szétválogatás
 - összefuttatás
- □ Ezeknél a feladatoknál a szekvenciális inputfájlt elemenként dolgozzuk fel, azaz az inputfájl elemeit annak olvasó műveletére támaszkodva felsoroljuk, és a megoldást az összegzés algoritmus mintára vezetjük vissza.

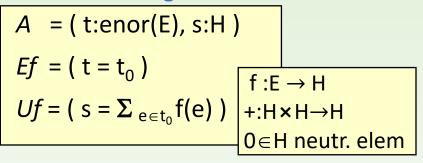
Szekvenciális inputfájl felsorolója

E-beli értékeket tartalmazó szekvenciális inputfájl elemeinek felsorolása



Összegzés fájlkezeléshez

Általános összegzés



Fájlfeldolgozás

```
A = (x:infile(E), y:outfile(F))
Ef = (x = x_0)
Uf = (y = \bigoplus_{e \in x_0} f(e))
f:E \to F^*
\bigoplus :F^* \times F^* \to F^*
<> \in F^* \text{ neutr. elem}
```

```
Összegzés:
t:enor(E) ~ x:infile(E) felsorolása
a st,e,x : read művelettel
```

H,+,0 ~ F*, ⊕, <>

```
s := 0
t.First()

¬t.End()

s := s+f(t.Current())

t.Next()
```

```
y := <>

st,e,x : read

st=norm

y : write(f(e))

st,e,x : read
```

C# nyelvi elemek

- □ Szöveges állomány hátterű szekvenciális inputfájlból egy egyedi TextFileStream típusú objektum segítségével olvashatjuk be az adatokat. Ehhez szükség van a TextFileStream.dll és a using TextFile hivatkozásra.
- □ Az st,e,x:read műveletet az e típusától függően eltérő utasítások helyettesítik, amelyek igaz értéket adnak vissza, ha st=norm
 - <u>karakterenkénti</u> olvasásnál: x.ReadChar(out char e)
 - <u>lexikális egységenkénti</u> olvasásnál: x.ReadInt(out int e)
 - x.ReadDouble(out double e)
 - x.ReadString(out string e)
 - x.ReadLine(out string e)
- □ Szöveges állomány hátterű szekvenciális outputfájlba egy szabványos StreamWriter objektum segítségével írhatunk adatokat. Ehhez szükség van a using System.IO hivatkozásra.
- □ Az y:write(e) műveletet az y.Write(e) utasítás helyettesíti, de teljes sorok kiírásához használhatjuk az y.WriteLine(e) utasítást is.

1. rész Karakterenkénti olvasás

Gregorics Tibor

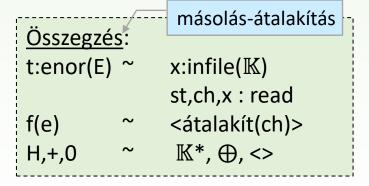
gt@inf.elte.hu

http://people.inf.elte.hu/gt/oep

1.Feladat

Alakítsunk át egy ékezeteket tartalmazó szöveget (szöveges állományt) ékezet nélkülire (az eredmény egy másik szöveges állományba kerüljön)!

```
A = (x:infile(\mathbb{K}), y:outfile(\mathbb{K})) Ef = (x = x_0) Uf = (y = \bigoplus_{ch \in x_0} < \text{átalakít(ch)} > ) ahol \ \ \text{átalakít} : \mathbb{K} \to \mathbb{K} \quad \text{és} \quad \text{átalakít(ch)} = ...
```



Szürkedoboz tesztelés

- ☐ Az összegzés teszteléséhez vizsgálni kell
 - a felsorolót
 - felsorolás hossza szerint: 0, 1, 2, illetve több elem felsorolása
 - felsorolás eleje, vége szerint: két eltérő betű felsorolásával már ellenőrizhető
 - a felsoroló skálázása most kevésbé fontos, hiszen az outputfájlt hossza meg fog egyezni az inputfájléval
- □ Ezeken kívül ellenőrizni kell a konverziót.

felsoroló szerint	hosszra:	x = <>, <a>, <ab>, <></ab>	\rightarrow	y = <>, <a>, <ab>, <></ab>
	elejére:	x = <ab>, <áé></ab>	\rightarrow	y = <ab>, <ae></ae></ab>
	végére:	x = <ab>, <áé></ab>	\rightarrow	y = <ab>, <ae></ae></ab>
átalakítás szerint	ék-es mgh:	x = <áéíöőúüű>	\rightarrow	y = <aeioouuu></aeioouuu>
	ék-tlen mgh:	x = <aeioouuu></aeioouuu>	\rightarrow	y = <aeioouuu></aeioouuu>
	msh:	x = <bsmnz></bsmnz>	\rightarrow	y = <bsmnz></bsmnz>

C# program

Karakterek átalakítása

```
static char Transform(char ch)
  char new_ch;
  switch (ch) {
     case 'á'
                                      new ch = 'a'; break;
     case 'é'
                                      new ch = 'e'; break;
     case 'í' :
                                      new ch = 'i'; break;
     case 'o' : case 'o' : new ch = 'o'; break;
     case 'ú' : case 'ü' : case 'û' : new ch = 'u'; break;
     case 'Á'
                                      new ch = 'A'; break;
     case 'É'
                                      new ch = 'E'; break;
     case 'Í' :
                                      new ch = 'I'; break;
     case '0': case '0': new ch = '0'; break;
     case 'Ú' : case 'Ü' : case 'Û' : new ch = 'U'; break;
     default
                                      new ch = ch; break;
  return new_ch;
```

2. rész Rekordonkénti olvasás

Gregorics Tibor

gt@inf.elte.hu

http://people.inf.elte.hu/gt/oep

2. Feladat (algoritmus minták szimultán alkalmazása)

Egy sportoló adott időközönként feljegyezte a pulzusszámát, és ezeket egy szekvenciális inputfájlban időpont-pulzusszám (sztring-természetes szám) párok sorozataként rögzítette. Gyűjtsük ki a legalább 100-as pulzusszámú méréseket, adjuk meg a mérések közt talált legmagasabb pulzusszámot, és mondjuk meg, hogy volt-e a pulzusszám 60-nál kisebb.

```
A = (x:infile(Mérés), y:outfile(Mérés), max:\mathbb{N}, volt:\mathbb{L})
Mérés = rec(idő:\mathbb{S}, pulzus:\mathbb{N})
Ef = (x = x_0 \land |x| > 0)
Uf = (y = \bigoplus_{e \in x_0} < e > \land (max, .) = MAX_{e \in x_0} e.pulzus \land e.pulzus \geq 100
\land volt = SEARCH_{e \in x_0} e.pulzus < 60)
|x_0| > 0 \text{ hiányában felt. max. ker. kellene:}
(I, max, .) = MAX_{e \in x_0} e.pulzus igaz
```

Összegzés:

t:enor(E) ~ x:infile(Mérés) st,e,x : read f(e) ~ <e> ha e.pulzus≥100 H,+,0 ~ Mérés*, ⊕, <>

Maximum kiválasztás:

t:enor(E) ~ x:infile(Mérés) st,e,x : read f(e) ~ e.pulzus

Lineáris keresés:

t:enor(E) ~ x:infile(Mérés) st,e,x : read felt(e) ~ e.pulzus<60

Szimultán feldolgozás közös felsorolón

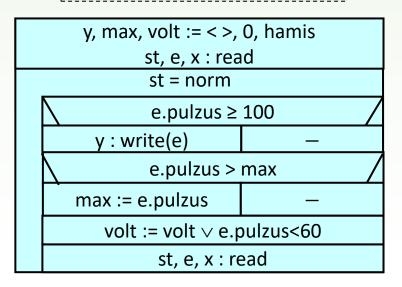
A részfeladatokat megoldó programokat össze kell vonni egy közös ciklusba, hiszen mind ugyanarra a meg nem ismételhető felsorolásra épülnek. Ehhez az összevonandó ciklusoknak szinkronban kell lenniük.

Szinkron működő mintákat használjunk

- max. kiv. helyett felt. max. ker., vagy összegzés, mivel itt a vizsgált értékeknél van kisebb

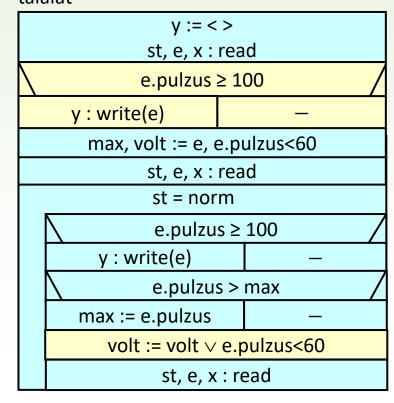
- lineáris keresés (eldöntés) helyett összegzés

f(e)
$$\sim$$
 e.pulzus < 60
H,+,0 \sim L, \vee , hamis



Programátalakítással szinkronizálunk

a felsorolás első elemét mindhárom részprogram a ciklus előtt dolgozza fel,
a lineáris keresés ne termináljon, ha volt találat



Szürke doboz tesztelés

- □ Vizsgálni kell
 - a felsorolót
 - felsorolás hossza: 0, 1, 2, több hosszú csupa 100 feletti mérés
 - felsorolás eleje: 100 feletti ill. 100 alatti mérés elől
 - felsorolás vége: 100 feletti ill. 100 alatti mérés hátul
 - az eredeti algoritmus minták szerint
 - összegzés: skálázás most sem érdekes
 - maximum kiválasztás: első, középső, vagy utolsó elem a maximum, több azonos maximum van
 - lineáris keresés: nincs keresett mérés, a keresett mérés az első, középső, vagy utolsó elem
 - a kiválogatás és a keresés feltételében: kisebb, nagyobb, egyenlő

Szekvenciális inputfile

```
class InFile
                                                             közös névtérben
                                                             a class Program -mal
 public struct Measurement
    public string time;
    public int pulse;
                                   a struct érték típus
                                   lehetne class is, de akkor new kell a létrehozáshoz
  private readonly TextFile.TextFileReader reader;
 public InFile(string fname)
    reader = new TextFile.TextFileReader(fname);
                                         st, e, x : read megvalósítása
                                         az x objektum metódusaként
 public bool Read(out Measurement dx)
    reader.ReadString(out time);
    return reader.ReadInt(out pulse);
```

Kódolás

```
st = norm
class Program
                                                                   e.pulzus ≥ 100
                                                             y: write(e)
  static void Main()
                                                                   e.pulzus > max
    try
                                                           max := e.pulzus
                                                              volt := volt \vee e.pulzus<60
      InFile x = new ("input.txt");
                                                                    st, e, x : read
      Console.WriteLine("Selected measurements:");
      int max = 0;
                                 st, e, x : read az x objektum metódusa
      bool low = false; 
      while (x.Read(out InpFile.Measurement e))
        if (e.pulse >= 100) Console.WriteLine($"time: {e.time}, pulse: {e.pulse}");
        if (e.pulse > max) max = e.pulse;
        low = low || e.pulse < 60;
      string ans = low ? "" : "not ";
      Console.WriteLine($"maxima: {max}, there is {ans}a low pulse");
    catch (System.IO.FileNotFoundException)
      Console.WriteLine("Could not open the textfile");
```

y, max, volt := < >, 0, hamis

st, e, x : read

3.Feladat (algoritmus minták egymás után egy felsorolón)

Egy sportoló adott időközönként feljegyezte a pulzusszámát, és ezeket egy szekvenciális inputfájlban időpont-pulzusszám (sztring-természetes szám) párok sorozataként rögzítette. A fájl időpont szerint növekedően rendezett. Hányszor mért 100-nál alacsonyabb pulzusszámot azt megelőzően, hogy először elérte a pulzusa a legalább 100-at, és mekkora volt a legalacsonyabb pulzusszáma ezt követően? Legalább egyszer biztosan mért 100-as pulzusszámot, és azt követően is voltak még mérések.

```
a felsorolás ezen feltétel fennállásáig tart A = (x:infile(Mérés), c:\mathbb{N}, min:\mathbb{N}) A = (x:infile(Mérés), c:\mathbb
```

lehet (. , . , x')-ot írni:

összegzés másodlagos outputja: st, e, x változók aktuális értékei st'=norm és e'.pulzus≥100

Összegzés:

t:enor(E) ~ x:infile(Mérés), st,e,x:read amíg: e.pulzus<100

f(e)
$$\sim$$
 1
H, +, 0 \sim N, +, 0

<u>ıvıınımum kiválasztás:</u>

t:enor(E) ~ x:infile(Mérés), st,e,x:read felsorolás folytatása

f(e) \sim e.pulzus H, > \sim N, <

Algoritmus

előfeltétel miatt

Összegzés:

t:enor(E) ~ x:infile(Mérés), st,e,x:read amíg: e.pulzus<100

f(e) ~ 1 H, +, 0 ~ N, +, 0

c := 0

st, e, x : read

e.pulzus < 100 \wedge st = norm

c := c + 1

st, e, x : read

Itt First() helyett Next() kell, de szekvenciális inputfájlnál ez így is, úgy is a read lesz

Minimum kiválasztás:

t:enor(E) ~ x:infile(Mérés), st,e,x:read felsorolás folytatása

~ e.pulzus f(e)

H, > ~ N, <

st, e, x : read

min := e.pulzus

st, e, x : read

st = norm

e.pulzus < min

min := e.pulzus

st, e, x : read

Kitérő

Hogyan módosul a megoldás második része, ha a minimum kiválasztásnak figyelembe kellene vennie az első legalább 100-as pulzusszámot is.

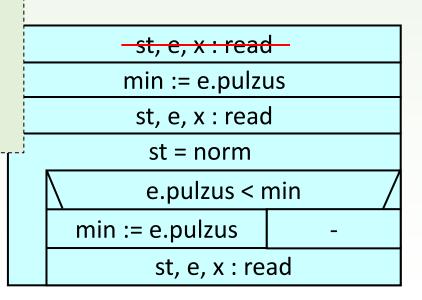
```
A = (x:infile(Mérés), c:\mathbb{N}, min:\mathbb{N}) \qquad Mérés=rec(idő:\mathbb{S}, pulzus:\mathbb{N}) Ef = (x = x_0 \land x \nearrow_{idő} \land \exists i \in [1...|x|] : x_i.pulzus \ge 100) \qquad figyelembe vesszük a már kiolvasott e' értéket is <math display="block">Uf = ((c, (.., e', x')) = \sum_{e \in x_0}^{e.pulzus < 100} 1 \land min = MIN_{e \in <e'} \rightarrow x' (e.pulzus))
```

t:enor(E) ~ x:infile(Mérés), st,e,x:read előre olvasás nélkül

f(e) ~ e.pulzus

Maxinmum kiválasztás:

H, > ~ N, <



Szürke doboz tesztelés

- □ Tesztelni kell külön-külön a felsoroló első szakaszán működő összegzést, és a hátsó szakaszán működő minimum kiválasztást.
 - Olyan inputfájlok kellenek, ahol a fájl első szakasza lehet 0, 1, 2 hosszú, vagy hosszabb, hátsó szakasza 1, 2 hosszú, vagy hosszabb.
 - Vizsgálni kell, hogy mindkét szakasz mindkét végét figyelembe veszie a számítás: az összegzésnél ehhez elég ha a fájl első két mérése 100-nál kisebb pulzusszámú, a minimum kiválasztásnál kell olyan input, amikor a hátsó szakasz első eleme tartalmazza a legkisebb pulzus számot, és olyan is, amikor az utolsó eleme.
 - A minimum kiválasztás tesztelésénél vizsgálni kell azt is, amikor a hátsó szakasz közepén van a legkisebb pulzus számú elem, illetve amikor több egyformán legkisebb pulzus számú elem is van.
- □ Végül érdemes az e.pulzus<100 feltételt is tesztelni 99, 100, 101 pulzus számokkal.

Kódolás

```
static void Main()
  try
    InFile x = new ("input.txt");
    InFile.Measurement e;
                     Infile osztályban (ami névtérként is funkcionál) definiált
    int c = 0;
    while (x.Read(out e) && e.pulse < 100) ++c;</pre>
    x.Read(out e);
    int min = e.pulse;
    while (x.Read(out e))
      if (e.pulse < min) min = e.pulse;</pre>
    Console.WriteLine($"count: {c}, min: {min}");
 catch(System.IO.FileNotFoundException)
    Console.WriteLine("Could not open the textfile");
```

3. rész Soronkénti olvasás

Gregorics Tibor

gt@inf.elte.hu

http://people.inf.elte.hu/gt/oep

4. Feladat (egymásba ágyazott algoritmus minták)

Több sportolónak mértük edzés közben a pulzusát, és a mérési adatokat soronként rögzítettük egy szöveges állományban.

Minden sor egy sportoló (több sztringből álló) nevével kezdődik, amelyet a mérési adatok követnek. Egy mérési adat egy időpontból (mm:ss formájú sztring), és egy pulzusszámból (természetes szám) áll. A sor adatait elválasztó jelek (szóközök, tabulátorjelek) választják el egymástól. Feltehetjük, hogy a mérések időpont szerint növekedően rendezettek.

Gyűjtsük ki azokat a sportolókat, akiknek pulzusszáma az első legalább 100-as mérés után 100 alá esett vissza.

```
      Gipsz Jakab Elemér
      00:01 67 01:15 89 02:55 102 04:03 108

      Szer Elek
      00:01 72 00:55 102 03:15 110

      Jose Fernando Llano del Colona
      00:01 67 02:30 100 04:55 95 06:03 105
```

Elemzés

fizikai elhelyezkedést szem előtt tartó

```
A = (x : infile(Sor), y : outfile(Sor)) Sor = \mathbb{S}^*,

Ef = (x = x_0 \land \forall e \in x : e olyan, hogy ...)

Uf = (...)
```

```
A = (x : infile(Sportoló), y : outfile(S)) bemenetet szem előtt tartó Sportoló = rec(név:S, mérések:Mérés*) Mérés=rec(idő:S, pulzus:N) Ef = (x = x_0 \land \forall e \in x : e.mérések \nearrow_{idő}) Uf = (y = \bigoplus_{e \in x_0} f(e)) f = ...
```

```
A = (x : infile(Sportoló), y : outfile(S)) kimenetet szem előtt tartó Sportoló = rec(név:S, alá:L)

Ef = (x = x_0)
Uf = (y = \bigoplus_{e \in x_0} < e.név > )
e.alá
```

Összegzés (kiválogatás):

t:enor(E) ~ x:infile(Sportoló)

e∈t ~ st,e,x :read

f(e) ~ ha e.alá akkor <e.név>

s ~ y

H,+,0 ~ S*, ⊕, <>

Kódolás

```
static void Main()
 try
   InputFile x = new ("input.txt");
   while(x.Read(out InputFile.Athlete e))
      if (e.below)
         Console.WriteLine(e.name);
 catch(System.IO.FileNotFoundException)
   Console.WriteLine("Could not open the textfile");
 catch(InputFile.EmptyRowException)
   Console.WriteLine("Could not open the textfile");
```

Felhasználói típusok

```
class InFile
                                                    infile(Sportoló)
                                                                   sx,dx,x:read
  public class EmptyRowException : Exception { } Sportoló*
                                                     r : infile(Sor)
  public struct Athlete
                                                    Sportoló = rec(név:S, alá:L)
    public string name;
    public bool below;
 private readonly TextFileReader reader;
  public InFile(string fname)
    reader = new TextFileReader(fname);
  public bool Read(out Athlete e) { ... }
```

Az olvasó (read) művelet

A soron következő sor feldolgozásával egy újabb sportoló adatait állítja elő.

```
A = (r:infile(Sor), e:Sportoló, st:Status)
                                              Sportoló = rec(név:S, alá:L)
                                         Ef = (r = r')
                                                                                  az aktuális sor
                                         Uf = ((|r'| > 0 \rightarrow st = norm \land
                                                            e = feldolgoz(r'_1) \land
                                                             r = \langle r'_{2}, ..., r'_{|r'|} \rangle \land
public bool Read(out Athlete e)
                                               (| r' | = 0 \longrightarrow st = abnorm)
  if (reader.ReadLine(out string line) )
                                                             amikor nincs több
                                                             sora az inputfájlnak
    if (line == "") throw new EmptyRowException();
    ... // processing the content of line
    return true;
  else
    e.name = ""; e.below = false;
    return false:
```

Egy sor feldolgozása

Szavakra (tokenekre) bontott sorban az első néhány szó alkotja a sportoló nevét, majd az első időpont adattól kezdve jönnek a mérések (időpontpulzusszám párok). Döntsük el van-e legalább 100-as pulzusszámú, és azt követően 100-nál kisebb pulzusszámú mérés.

```
Gipsz Jakab Elemér 00:01 67 01:15 89 02:55 102 04:03 108
                    minden sort tokenekre (szavakra) bontunk
A = (sor : \mathbb{S}^*, e : Sportoló) Sportoló = rec(név:\mathbb{S}, alá:\mathbb{L})
                                                  összefűzzük egy névvé az
Ef = (sor = sor')
                                                  első időpont előtti szavakat
      az első időpont
         elso idopont (e.név, (név", sor")) = \bigoplus_{név \in sor'} név = (név)
                                                                 majd megkeressük az első legalább
       a sor hátralevő része
                                                                 100-as pulzusszámú mérést
                                                                      (pulzus≥100)
            \wedge (I1, ( . , sor''') = SEARCH
                                           (idő, pulzus)∈<név">⊕so
 a sor hátralevő része
                                                                     felsorolás folytatása a név"
                                                                     felhasználásával, de innentől
                              (idő, pulzus)∈sor''' (pulzus<100)
            \wedge 12 = SEARCH
                                                                     már szópárokat kell olvasni
                                                         végül eldöntjük, van-e 100-nál kisebb mérés
            \wedge e.alá = ( |1 \wedge |2 \rangle
                                                         az első legalább 100-as pulzusszám után
```

Egy sor feldolgozása

```
char[] separators = new char[] { ' ', '\t' };
                                                        szavakra való tördelés
string[] tokens
       = line.Split(separators, StringSplitOptions.RemoveEmptyEntries);
e.name = "";
int i = 0;
                                       szavak felsorolása egyesével
foreach (string str in tokens)
                                       összefűzés feltétel fennállásáig
   if (str[2] == ':') break;
   e.name += str + " ";
   ++i;
                                          szavak felsorolása kettesével
bool 11 = false;
for (++i; i < tokens.Length; i += 2)
                                                      lineáris keresés
   if (l1 = (int.Parse(tokens[i]) >= 100) ) break;
                                          szavak felsorolása kettesével
bool 12= false;
for (i += 2; i < tokens.Length; i += 2)
                                                      lineáris keresés
   if (12 = (int.Parse(tokens[i]) < 100) ) break;</pre>
e.below = 11 \&\& 12;
return true;
```

Szürkedoboz tesztelés vázlata

kiválogatás (feltételes összegzés):

a felsoroló hossza szerint: 0, 1, 2, több feltételnek megfelelő sportoló

<u>a felsorolás</u> eleje/vége: csak az első és utolsó sportoló felel meg a feltételnek

terhelés: nem kell

névtagok összefűzése (összegzés):

a felsoroló hossza szerint: 1, 2, több névtagú sportoló

a felsorolás eleje/vége: előzővel letudva

legalább 100-as mérés keresése (lineáris keresés) :

a felsoroló hossza szerint: 0, 1, 2, több mérés az első legalább 100-as mérés előtt

<u>a felsorolás</u> eleje/vége: előzővel letudva

eredmény szerint: 99, 100, 101

100 alatti mérés keresése (lineáris keresés):

a felsoroló hossza szerint: 0, 1, 2, több mérés az első legalább 100-as mérés után

a felsorolás eleje/vége: elején, illetve a végén 100 alatti mérés

eredmény szerint: 99, 100, 101